

SIAKAD Assist

Chatbot FAQ Akademik Berbasis TF-IDF dan Logistic Regression Universitas Mercu Buana

Mata kuliah	Natural Language Processing
Kelompok	Anggota 1 · Anggota 2 · Anggota 3
Domain	FAQ akademik kampus
Tanggal	27 Juli 2026

Ringkasan hasil: 250 utterance seimbang, 5 intent, accuracy 98,00%, macro F1 97,99%, serta dukungan CLI dan UI Streamlit dengan log CSV.

1. Pendahuluan dan Identifikasi Masalah

Mahasiswa membutuhkan jawaban cepat untuk pertanyaan berulang tentang KRS, pembayaran UKT, jadwal ujian, beasiswa, dan akses portal. Informasi tersebar pada beberapa kanal sehingga pertanyaan sederhana tetap membebani layanan akademik. Proyek ini merancang chatbot NLP sederhana yang memberi jawaban awal dan memandu simulasi KRS tanpa menggantikan keputusan petugas kampus.

1.1 Tujuan dan Batas Sistem

Tujuan sistem adalah mengenali intent pertanyaan mahasiswa, mengekstrak slot NIM serta pilihan mata kuliah, mempertahankan konteks percakapan, meminta konfirmasi, dan menyimpan log. Sistem menggunakan data dummy dan tidak melakukan transaksi atau perubahan pada SIAKAD produksi.

1.2 Kebutuhan Fungsional

ID	Kebutuhan	Status
F-01	Menerima teks dari CLI dan UI Streamlit	Terpenuhi
F-02	Mengklasifikasikan lima intent FAQ	Terpenuhi
F-03	Mengekstrak NIM dan nomor mata kuliah dengan regex	Terpenuhi
F-04	Menjalankan dialog KRS multi-turn dan konfirmasi	Terpenuhi
F-05	Memberi fallback untuk confidence rendah/input invalid	Terpenuhi
F-06	Menyimpan log CSV dengan masking NIM	Terpenuhi

2. Teori Singkat NLP


Natural Language Processing (NLP) mempelajari metode komputasional untuk memproses bahasa manusia. Pada chatbot berbasis intent, teks dinormalisasi lalu diubah menjadi fitur numerik. TF-IDF memberi bobot tinggi pada istilah yang informatif dalam sebuah dokumen tetapi relatif jarang pada keseluruhan korpus [1][2].

Logistic Regression memperkirakan probabilitas kelas dan sesuai untuk fitur teks sparse. Prediksi dievaluasi melalui accuracy, precision, recall, F1-score, dan confusion matrix. Precision menilai ketepatan prediksi positif, recall menilai cakupan data kelas yang ditemukan, sedangkan F1 menyeimbangkan keduanya [3][4].

3. Dataset dan Preprocessing

Dataset berisi 250 utterance berbahasa Indonesia. Lima intent dibuat seimbang untuk mengurangi bias kelas. Variasi mencakup bahasa formal, percakapan mahasiswa, singkatan, typo ringan, dan susunan pertanyaan berbeda.

Intent	Jumlah	Proporsi
akses_portal	50	20%
jadwal_ujian	50	20%
pembayaran_ukt	50	20%
pendaftaran_krs	50	20%
syarat_beasiswa	50	20%




Gambar 1. Distribusi dataset per intent (masing-masing 50 utterance).

3.1 Tahap Preprocessing

- Lowercase: menyamakan kapitalisasi.
- Cleaning: menghapus tanda baca dan karakter khusus.
- Tokenization: memecah teks berdasarkan token kata.
- Normalisasi: memperbaiki singkatan/typo seperti bgmn menjadi bagaimana.

Intent	Sebelum	Sesudah
pendaftaran_krs	Bagaimana cara pengisian KRS semester ini?	bagaimana cara pengisian krs semester ini
pembayaran_ukt	saya mau bayar ukt lewat mandiri bagaimana	saya mau bayar ukt lewat mandiri bagaimana
jadwal_ujian	di mana lihat jadwal uts dan uas	di mana lihat jadwal uts dan uas
syarat_beasiswa	apa saja syarat mendaftar beasiswa bca	apa saja syarat mendaftar beasiswa bca
akses_portal	bagaimana cara mengakses portal siacad	bagaimana cara mengakses portal siacad

4. Desain dan Implementasi




Gambar 2. Arsitektur pemrosesan chatbot.

Representasi teks menggabungkan word n-gram (1-2) dan character n-gram (2-5) melalui FeatureUnion. Character n-gram membuat model lebih tahan terhadap typo, sedangkan word n-gram mempertahankan pola makna. Logistic Regression menggunakan `class_weight=balanced`, `C=2,0`, dan `random_state=42`.

4.1 Slot Filling dan Dialog Manager

Slot filling menggunakan regex untuk mencari NIM 10-12 digit serta nomor mata kuliah. DialogManager menyimpan state dan konteks sehingga pesan berikutnya dapat ditafsirkan sesuai tahap proses. Jawaban konfirmasi yang ambigu tidak langsung membatalkan proses, tetapi meminta pengguna menjawab ya atau batal.

Flow dialog pengisian KRS



Gambar 3. State diagram alur KRS multi-turn.

4.2 Struktur Data Percakapan dan Log

Dataset intent menggunakan pasangan `{text, intent}`. Database demo memuat mahasiswa, program studi, semester, katalog mata kuliah, SKS, dan biaya. Log CSV menyimpan timestamp, session ID, kanal, pesan pengguna, respons, intent, confidence, state sebelum, dan state sesudah. NIM disamarkan sebelum log ditulis.

4.3 Implementasi CLI dan UI


CLI dijalankan dengan python3 `cli_app.py` dan menyediakan bantuan, reset, keluar, serta metadata prediksi. UI Streamlit memakai elemen chat resmi, quick actions, indikator state, unduh log, dan tampilan responsif tanpa aset eksternal [5].

5. Evaluasi dan Analisis

Dataset dibagi secara stratified menjadi 200 data latih dan 50 data uji (80:20). Seed 42 digunakan agar hasil dapat direproduksi. Tabel berikut memakai macro average agar setiap intent memiliki bobot yang sama.

Metrik	Hasil
Accuracy	98.00%
Precision (macro)	98.18%
Recall (macro)	98.00%

Metrik	Hasil
F1-Score (macro)	97.99%
F1-Score (weighted)	97.99%



Gambar 4. Confusion matrix pada 50 data uji.

5.1 Intent yang Paling Sering Salah

Terdapat 1 kesalahan. Intent pendaftaran_krs salah diprediksi sebagai syarat_beasiswa pada kalimat "saya ingin daftar mata kuliah semester depan". Kata 'daftar' dan frasa waktu 'semester depan' juga sering muncul pada konteks pendaftaran beasiswa, sehingga fitur leksikal kedua kelas beririsan.

5.2 Penyebab Kesalahan dan Keterbatasan

- Dataset masih disusun untuk cakupan proyek dan belum berasal dari log produksi nyata.
- Model mengandalkan kemiripan leksikal sehingga pertanyaan sangat pendek atau ambigu dapat tertukar.
- Sistem hanya mendukung lima intent serta dua jenis slot utama.
- Confidence probabilistik belum dikalibrasi khusus dan threshold 0,35 bersifat empiris.
- Informasi biaya, jadwal, syarat, dan portal harus diverifikasi melalui kanal resmi kampus.

6. Pengujian Sistem

Automated tests mencakup validitas dataset, preprocessing, pipeline model, slot filling, state machine, konfirmasi ambigu, masking NIM, logger, CLI, dan UI. Pengujian manual menggunakan tiga skenario: FAQ UKT, jadwal ujian dengan follow-up portal, serta alur KRS lengkap sampai konfirmasi.

Skenario	Input utama	Hasil yang diharapkan
FAQ UKT	cara bayar ukt melalui bca	Intent pembayaran_ukt dan respons prosedur
Follow-up	jadwal uas ... / portalnya di mana	Konteks diarahkan ke akses_portal
KRS multi-turn	KRS / NIM / 1,2 / ya	State selesai dan konfirmasi berhasil

7. Kesimpulan

Chatbot FAQ Akademik berhasil memenuhi komponen utama rubrik: dataset 250 data, preprocessing, TF-IDF, Logistic Regression, regex slot filling, dialog multi-turn dengan konfirmasi, evaluasi lengkap, CLI, UI, dan log CSV. Accuracy 98,00% menunjukkan model efektif untuk dataset proyek, tetapi perlu perluasan data nyata dan integrasi sumber resmi sebelum diterapkan sebagai layanan kampus.

8. Pembagian Tugas

Anggota	Peran	Kontribusi
Anggota 1	Data & NLP	Dataset, preprocessing, pelatihan model
Anggota 2	Backend	Slot filling, dialog manager, CLI, logging
Anggota 3	UI & Evaluasi	Streamlit, pengujian, laporan, slide

Daftar Pustaka

- [1] D. Jurafsky dan J. H. Martin, Speech and Language Processing, edisi ke-3, draft daring, Stanford University, 2026.
<https://web.stanford.edu/~jurafsky/slp3/ed3book.pdf>
- [2] Scikit-learn Developers, TfidfVectorizer Documentation.
https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html
- [3] Scikit-learn Developers, LogisticRegression Documentation.
https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html
- [4] Scikit-learn Developers, Metrics and Scoring: Quantifying the Quality of Predictions.
https://scikit-learn.org/stable/modules/model_evaluation.html
- [5] Streamlit, Chat Elements API Documentation. <https://docs.streamlit.io/develop/api-reference/chat>